Teoría de Aprendizaje de maguina / Juan Jerónimo Castaño Rivera 1) Sea el modelo tn= \$ (xn) wT + nn, En EIR, xn EIR WEIRP, DEIRPORP 1 1 ~ N(n10, 0,2) De forma material t= DIW + 12 Donde \$ EIRNA = Patos € E IRN : Vector de salida WEIRA - Modelo - Minimos Cuadrados Optimización W + argmin 1 11 & - DW112 El vulor mínimo se puede hallar derivando e igualando a cero 11t- 01w 1/2 = < tt- ow. t-ow> = (t- ow) (t - ow) = # + + + + + + (+ w) + + (+ w) + (+ 2 15th - 2th ow + (ow) 7 (ow) 7 = 0 = 0 - (2 t T P) T + Z O DW = 0 - Z OTE + 2 O TOW = 0 = 2 OTE = Z OTOW (0 0 0) -1 (0 0 0) W = (0 0) -1 0 = # W= (00000t

- Minimos Cuadrados regularizados W= argmin 11 # - 0 W112 + 111W112 W+ 2 SIIH - DW1/2 + 211 W1/2 3 = 0 =) -2 0 t +2 0 ow + 2 liw = 0 (2000 + 2) II) w= 200 to W* = (0 T 0 +) I) - 1 OT # - Maxima verosimilitud tn= &(xn) 2 w + 1/n; n~ N(0,0,2) Se puede ver que p (tn/xn, w) = N (tn/ p(xn) w, on2)

Nado que son ii d Tl p (tn/ p(xn) w, on2) log (Ti p (tal Oniw, on2)) = log (Ti 1 exp (- 1tn - Oniw 2)) - Nlog (1) - 1 & Ita- Onlw 12 = - N log(2 non2) - 1 Elta- Oalw |2 Se deriva e iguala a cero, el problema corresponde a mínimos cuadrados W+ = argmin - 1 202 11t - Owllz - 2 log(2002) W = (\$ 0) - 1 \$ TE

- Maximo a-posteriori En lagar de encontrar el valor de w que maximiza la verosimilitad, se asume un prior sobre w y buscamos el valor que maximiza la posterior w = argmax p(w/t) p(t,w)= p(w,t) =) p(t/w/p(w)= p(w/t)p(t) plult)- pltlw/plw/ plt) Para simplificar p(t): 1 Al ignal que en máxima veros imilitad P(t(w)= TT N(tn1 p(xn) w, on2) p(w)= N(w10, ow2) = 11 N(Wal O, Ow) = log (TT p(En l On W, On 2) To p(wol 0, ow)) 2 log (TT 1 exp (-1tn-pw/2) + log (TT 1 exp (-1 wg/2)) = log (TT 1) + log (TT exp (- ltn-pw/2) + log (TT 1) + log/ TI exp (- 1 wg/2) = - N log (2 non2) - Q log (2 no a2) - 1 E Ita- on w/2 1 E Iwg/2 W= min [| t - 0 W | 2 + 20 n2 | | w |] Min. cuad. regularizados W* = (0 10 + 0, 2 II) 07 t

Bayesiano Con modelo lineal Gaussiano Este modelo ao solo busa un cinico vector w, sino la distribución completa posterior sobre un dados los datos observados p(wit): N(w/ man, En) EN: Matriz covavianza EN= (1 1 + 1 0 2 0) mn = 1 Ev pt Optimización: Maximiza, la evidencia plt)= (plt lw) plw) dw Remostration. Seq un vedor X & IR & con prior Gaussian 0(x) = N(x) M 1-1) Sea el modelo y=Axtb = p(y 1x)=N(y 1Ax+b, 1-1) ρ(x,y)=ρ(x)ρ(y(x) =) ρ(x | y)= N(x | μχιγ, Ξχιγ) Ξ= (Δ+ Α Τ Δ)-1; μχιγ= Ξχιγ (Α Τ L(y-b) + Δμ) Para nuestro caso En= Q(xn) w + 1/n t= pw+17; p(t/w)=N(t/ow,on2) Se asume p(iw) = N(iw/mo, so) Subemos que logo(+ hw) = - 1 11 th - pw 1/2 + cte. log (N(x lu, E)= -1 (x-u) E (x u) - 1 log (E) - n log (en Por tato log(p(w)) == 1 (w-mo) TS-1 (w-mo) + cte log(p(th)w) = log(p(th))+log(p(w))

= - 7 (= 1 (t-0 m) (t-0 m) + (w-mo) 50 (w-mo) (+ cte Agrapando terminos W 7 (1 0 7 0 + 50 -1) W - Z W 7 (1 0 7 E + 50 - 1 mo) Se sabe que log(p(w)) - 1/2 (W-Mo) 150-1 (W-Mo) = - = (WTS-1 W - 2 WTS-1 mo + mot 80 1 mo) SN = (1 0 0 + 50-1 -1 SN MN = (1 0 1 + 50 1 mo) MN: SN (50 mo + 12 0 t) como plw1: N(W/mo, So) = N(W/O, Ow) SN = (1 II + 1 0 0 0) -1 MN: 1 SN DTE $m_{N} = \left(\frac{1}{\sigma_{n^{2}}}\right) \left(\frac{n}{\sigma_{n^{2}}}\right)^{-1} \left(\frac{\sigma_{n^{2}}}{\sigma_{W^{2}}} \mathbf{I} + \mathbf{\Phi}^{\mathsf{T}} \mathbf{\Phi}\right)^{-1} \mathbf{\Phi}^{\mathsf{T}} \mathbf{t} = \left(\frac{\sigma_{n^{2}}}{\sigma_{W^{2}}} \mathbf{I} + \mathbf{\Phi}^{\mathsf{T}} \mathbf{\Phi}\right)^{-1} \mathbf{\Phi}^{\mathsf{T}} \mathbf{t}$ - Regressión vígida Kernel Se extiende a espacios de funciones no lineales VI= piw; PEIRNOD; Q > 00 (RKHS) ¥ : 12 0 → 1R W= argmin 1 11t - OWILZ + AllwllH For minimos chadrados IN = (pt p + XI) - 1 OT E Sin embargo O' Q E IR QXQ; Q > 0 (ゆでの+入工)ーカナ = (入(力のゆ+工)ーカナー フ (エナのでの)ーゆす

Φ 1/I + Q Φ) - - - Φ (/ I + Φ Φ) - 1 W = pT() I + ppT)-1 t E had prediction para nuevos puntos f(Xx)= \$\phi(Xx)\ \implies K= O OT , K = - ((X)) T OT f(xx)=[K+()](K+)I[t - Gaussian Process Extienden el método paramétrico para definir la incertidambre de los parámetros del regresor al imponer un prior sobre fanciones directamente en EXTLS El GP se define por su media y covarianza f(x) & IR; f(x) Q(x) TW; p(w)=N(wlo, Sw), Eweren cov (f(x), f(x')) = x(x,x') = \$(x)^7 \(\xi \w \phi(x') \) f~GP(flo,K); K=[K(x,x)] € 12 NON Este modelo busca maximizar la verosimilitad p(t10), siendo 0 un hiperparametro de Kli, 10) Se puede obterer que m(Xx)=Kx(K+0211)-1+ , lKx=[K(Xx, Xxd, K(Xx, Xxd), ..., K(Xx, Xxd)] COV(f(x),f(x)) = K(X*,X*) + OE - K, (K+ Oc I) - 1K*